


ΤΜΗΜΑ ΜΗΧΑΝΙΚΩΝ Η/Υ & ΠΛΗΡΟΦΟΡΙΚΗΣ

ΠΑΝΕΠΙΣΤΗΜΙΟ ΙΩΑΝΝΙΝΩΝ

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

CONDITIONAL NEURAL NETWORKS



ΜΑΡΙΝΑ ΣΙΧΛΙΜΙΡΗ ΑΜ : 3072

ΦΕΒΡΟΥΑΡΙΟΣ 2022

ΕΠΙΒΛΕΠΩΝ

ΚΩΝΣΤΑΝΤΙΝΟΣ ΜΠΛΕΚΑΣ

Επισκόπηση

Σκοπός αυτής της διπλωματικής εργασίας είναι να αναλυθεί ένα νέο είδος νευρωνικών δικτύων, τα υπό όρους νευρωνικά δίκτυα ή, αλλιώς, Conditional Neural Networks (CLNNs) καθώς και η επέκτασή τους, τα Masked Conditional Neural Networks (MCLNNs), στα πλαίσια ανάπτυξης της επιστήμης της Μηχανικής Μάθησης. Έχοντας κατανοήσει τον τρόπο λειτουργίας των παραπάνω νευρωνικών δικτύων εφαρμόσαμε τόσο τα CLNNs όσο και τα MCLNNs στο πρόβλημα της ταξινόμησης εικόνων (image classification), χρησιμοποιώντας το σύνολο δεδομένων FASHION MNIST. Έτσι λοιπόν παρακάτω θα αναλυθούν:

- η δομή των Conditional Neural Networks και των Masked Conditional Neural Networks,
- η λειτουργικότητά τους,
- η εφαρμογή τους σε ένα σύνολο δεδομένων
- η αποτελεσματικότητά τους μέσα από τα πειράματα- εξομοιώσεις
- συμπεράσματα συμπεριλαμβανομένης της συνάρτησης ακρίβειας (accuracy) και απώλειας (loss) του σετ δοκιμών μας.

Περιεχόμενα

01

Νευρωνικά Δίκτυα

Εισαγωγή,
Βαθιά Μάθηση (Deep Learning)

02

CLNNs

Ανάλυση,
Προτεινόμενη Προσέγγιση

03

Masked CLNNs

Ανάλυση,
Προτεινόμενη Προσέγγιση,
Rectangle Mask Matrix schema

04

Πειραματικές μετρήσεις


Πειράματα, Τεχνικές
Λεπτομέρειες, Συμπεράσματα



01

Νευρωνικά Δίκτυα

Εισαγωγή,
Βαθιά Μάθηση (Deep Learning)



Νευρωνικά Δίκτυα

Είναι

δίκτυα από απλούς
υπολογιστικούς κόμβους
(νευρώνες),
διασυνδεδεμένους μεταξύ
τους

Αποτελούνται

από την είσοδο , ένα ή
περισσότερα κρυμμένα
επίπεδα και την έξοδο

Εκπαιδεύονται

αναλύοντας παραδείγματα
με γνωστή είσοδο και έξοδο

Αξιολογούνται

με βάση τη διαφορά της
πρόβλεψης (prediction) και
του πραγματικού
αποτελέσματος
(correct value)

Χρησιμοποιούν


διάφορες παραμέτρους για
να βελτιώσουν την ακρίβεια
(accuracy) και να περιορίσουν
τις εσφαλμένες προβλέψεις

Έχουν

ευρεία εφαρμογή σε
προβλήματα ταξινόμησης,
όπως image classification ,
sound classification κτλ.


Παραδείγματα Νευρωνικών Δικτύων

- Τεχνητό νευρωνικό δίκτυο (Artificial NN) με ένα κρυμμένο επίπεδο.




Παραδείγματα Νευρωνικών Δικτύων

- Βαθύ νευρωνικό δίκτυο (Deer NN) με πέντε κρυμμένα επίπεδα.



Παραδείγματα Νευρωνικών Δικτύων

- Επαναλαμβανόμενο νευρωνικό δίκτυο (Recurrent NN).

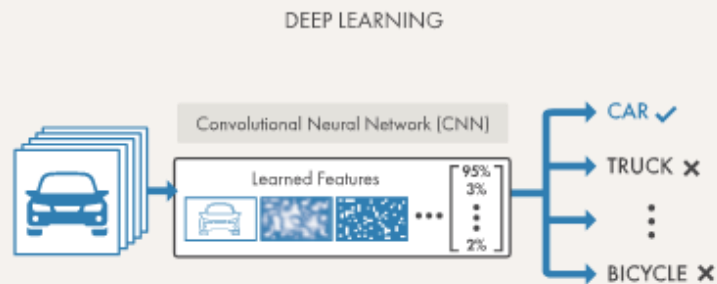
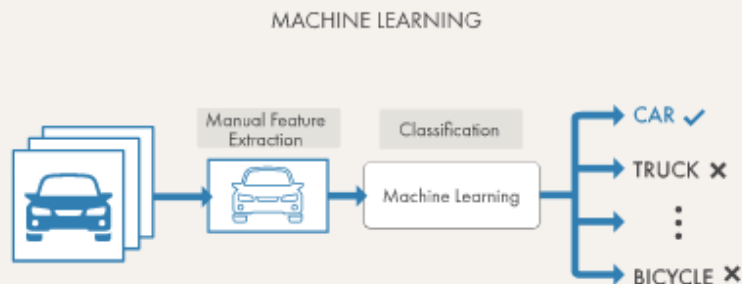


Βαθιά Μάθηση (Deep Learning)

- Τα Νευρωνικά Δίκτυα αποτελούν έναν κλάδο της Βαθιάς Μάθησης, ενώ και τα δύο μαζί περιλαμβάνονται στην Μηχανική Μάθηση.
- Η Βαθιά Μάθηση είναι ένα είδος Μηχανικής Μάθησης που είναι πολύ εξειδικευμένο.
- Ο τρόπος με τον οποίο μαθαίνει ο κάθε αλγόριθμος είναι το σημείο διάκρισης της Βαθιάς Μάθησης και της Μηχανικής Μάθησης. Η Βαθιά Μάθηση **αυτοματοποιεί ένα σημαντικό μέρος της διαδικασίας εξαγωγής χαρακτηριστικών**, αφαιρώντας μέρος της ανάγκης για χειροκίνητη ανθρώπινη συμμετοχή και επιτρέποντας έτσι τη χρήση μεγαλύτερων συνόλων δεδομένων (Big Data). Είναι δηλαδή κάτι σαν «κλιμακούμενη μηχανική μάθηση»
- Αντίθετα η κλασική Μηχανική Μάθηση, συχνά γνωστή ως «μη βαθιά» Μηχανική Μάθηση, **βασίζεται περισσότερο στην ανθρώπινη βοήθεια για τη μάθηση**. Το σύνολο των χαρακτηριστικών που χρησιμοποιούνται από τους ειδικούς για την ερμηνεία των διακρίσεων μεταξύ των πηγών δεδομένων καθορίζεται συνήθως από πιο δομημένα δεδομένα.

Σύγκριση των δύο τεχνικών

➤ Vehicle classification



02

CLNNs

Ανάλυση,
Προτεινόμενη Προσέγγιση

Conditional Neural Networks (CLNNs)

Υπό όρους Νευρωνικά Δίκτυα
(Conditional Neural Networks)



Δέντρα Απόφασης
(Decision Trees)



Συνελικτικά Νευρωνικά Δίκτυα
(Convolutional Neural Networks)

Conditional Neural Networks (CLNNs)

Υπό όρους Νευρωνικά Δίκτυα
(Conditional Neural Networks)



επαυξημένα δέντρα απόφασης
με τελεστές μετασχηματισμού
δεδομένων.



συνελικτικά νευρωνικά δίκτυα
με αραιούς πίνακες βαρών και
σαφώς ορισμένες συναρτήσεις
δρομολόγησης δεδομένων.

Conditional Neural Networks (CLNNs)

Υπό όρους Νευρωνικά Δίκτυα
(Conditional Neural Networks)



Είναι δέντρα απόφασης με την εξαίρεση ότι κάθε κόμβος αντί να παραδώσει την είσοδο ως έχει, εφαρμόζει έναν μη γραμμικό μετασχηματισμό σε αυτόν και προωθεί τα δεδομένα σε ένα ή περισσότερα παιδιά



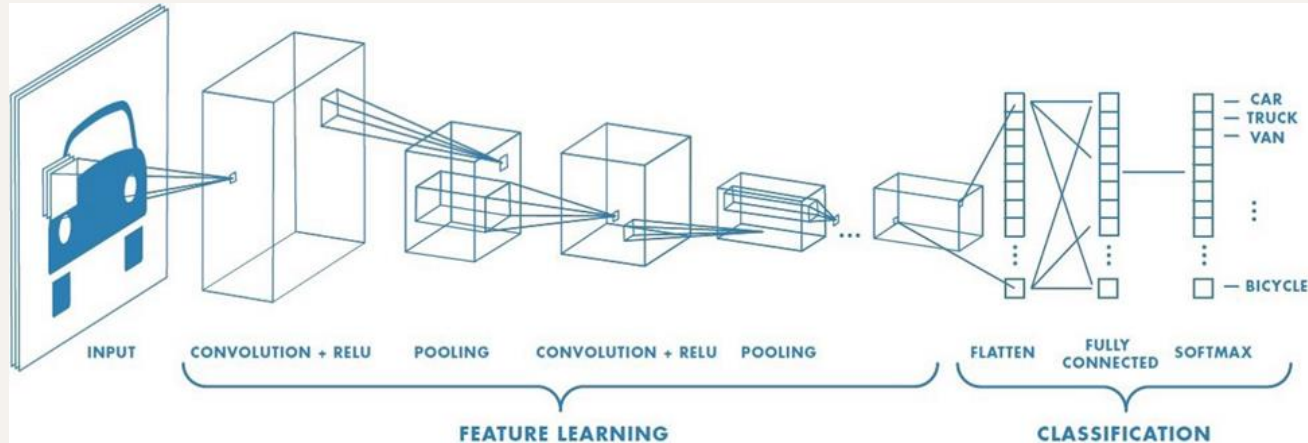
θεωρούμε ολόκληρο το μοντέλο ως ένα νευρωνικό δίκτυο, με συνδεδεμένα στρώματα μπλοκ αντί για εντελώς συνδεδεμένα στρώματα.

Συνελικτικά Νευρωνικά Δίκτυα

- Τα συνελικτικά νευρωνικά δίκτυα (CNN) είναι ένας τύπος τεχνητού νευρωνικού δικτύου που χρησιμοποιείται για την ερμηνεία εικόνων στη βαθιά μάθηση.
- Convolutional Layer: ύπαρξη ενός kernel (πίνακας πολύ μικρών διαστάσεων) και εκτέλεση της πράξης της συνέλιξης σε ολόκληρο τον πίνακα εισόδου. Στην συνέχεια εφαρμόζεται η συνάρτηση ReLU
- Pooling Layer: Μείωση διάστασης του αποτελέσματος
- Convolutional Layer + Pooling Layer = εφαρμόζονται σε κάθε επίπεδο του νευρωνικού δικτύου.

Συνελικτικά Νευρωνικά Δίκτυα

- Ευρεία εφαρμογή στην κατηγοριοποίηση εικόνας



Ανάλυση CLNNs

Ας υποθέσουμε ότι η είσοδος του υπό όρους νευρωνικού δικτύου αποτελείται από x κόμβους. Θα κατασκευάσουμε (συνεχόμενες) ομάδες κόμβων (πλαίσιο) μεγέθους d τέτοιες ώστε να ισχύει η παρακάτω σχέση:


$$d = 2n + 1, \quad n \geq 1$$

όπου n είναι μία παράμετρος που ορίζει πόσους γειτονικούς κόμβους εκατέρωθεν ενός ορισμένου κόμβου x_0 που εξετάζουμε θα συμπεριλάβουμε στην ομάδα του x_0 .

Κάθε τέτοια ομάδα d θα παράγει έναν νέο κόμβο του επόμενου επιπέδου.

Ανάλυση CLNNs

Σχηματική αναπαράσταση:



Ανάλυση CLNNs

Αναφορικά με την αρχιτεκτονική και δομή των υπό όρων νευρωνικών δικτύων, θα πρέπει να υπάρχουν q κόμβοι σε κάθε επίπεδο:

$$q = (2n) m + k, \quad n, m, \text{ and } k \geq 1$$


όπου n είναι η παράμετρος που ορίζει πόσους γειτονικούς κόμβους εκατέρωθεν ενός ορισμένου κόμβου x_0 που εξετάζουμε θα συμπεριλάβουμε στην ομάδα του x_0 , m είναι ο αριθμός των επιπέδων, k είναι ο ελάχιστος αριθμός κόμβων που θα πρέπει να παραμείνουν ώστε να μετατραπούν σε απλό διάνυσμα (flatten).

Κάθε επόμενο επίπεδο θα έχει $q-2n$ κόμβους σε σχέση με το προηγούμενό του που έχει q .


Ανάλυση CLNNs

- Επαναλαμβάνουμε την διαδικασία για όλους τους κόμβους ενός επιπέδου και στο τέλος θα έχουμε δημιουργήσει το επόμενο επίπεδο. Το παραπάνω εκτελείται μέχρι να φτάσουμε τους k κόμβους που έχουμε ορίσει αρχικά.
- Στην συνέχεια οι k κόμβοι μετατρέπονται σε απλό διάνυσμα (συνάρτηση flatten) όπου και θα ακολουθήσει η τελική κατηγοριοποίηση.
- Για την δημιουργία ενός νέου κόμβου χρησιμοποιούνται οι κόμβοι του αντίστοιχου πλαισίου d στους οποίους εφαρμόζεται η συνάρτηση ενεργοποίησης ReLU, ενώ στο επίπεδο της τελικής κατηγοριοποίησης σε κάποια κλάση εφαρμόζεται η συνάρτηση ενεργοποίησης SoftMax

Ανάλυση CLNNs



ReLU Function













SoftMax Function

Σύνολο Δεδομένων Fashion MNIST

- Το σύνολο δεδομένων Fashion MNIST αποτελείται από εικόνες 10 διαφορετικών αντικειμένων ένδυσης. Προέρχεται από το σύνολο δεδομένων MNIST, το οποίο και αντικατέστησε λόγω απλότητας, που αποτελείται από χειρόγραφα ψηφία.
- Training set : **60.000** εικόνες, Test set : **10.000** εικόνες
- Κάθε εικόνα έχει διαστάσεις **28 x 28** εικονοστοιχεία, συνολικά **784** εικονοστοιχεία ανά εικόνα. Κάθε εικονοστοιχείο έχει μια ενιαία τιμή εικονοστοιχείου που υποδεικνύει τη φωτεινότητά του, με τιμές από **0** έως **255** (ασπρόμαυρες εικόνες) .
- Κάθε εικόνα ανήκει σε μία από τις 10 ορισμένες κλάσεις όπως φαίνεται στο παρακάτω σχήμα:

Σύνολο Δεδομένων Fashion MNIST

Label	Description	Examples
0	T-Shirt/Top	
1	Trouser	
2	Pullover	
3	Dress	
4	Coat	
5	Sandals	
6	Shirt	
7	Sneaker	
8	Bag	
9	Ankle boots	

Προτεινόμενη προσέγγιση CLNNs

- Στην δική μας προσέγγιση ορίζουμε $m=3$ κρυμμένα επίπεδα (First Hidden layer, Second Hidden layer και Output layer) , $n=3$ γειτονικούς κόμβους εκατέρωθεν και επειδή $q=28$ λόγω της διάστασης της εικόνας προκύπτει ότι οι τελικοί κόμβοι που θα μετατραπούν σε single vector θα είναι $k=10$. [$q=(2n)m+k$]
- Ακόμη η κάθε ομάδα-πλαίσιο θα αποτελείται από $d=7$ κόμβους [$d=2n+1$]
- Input: εικόνα διάστασης **28 x 28** και Output ακέραιος αριθμός από **0** έως **9** (κλάση).
- Σύμφωνα με όλα τα παραπάνω τα επίπεδα έχουν ως εξής:

Προτεινόμενη προσέγγιση CLNNs

- Input layer: αποτελείται από **784** κόμβους (εικόνα **28 x 28** , $q=28$ διανύσματα με διάσταση **1x28**)

Σύμφωνα με τις σχέσεις που πρέπει να ισχύουν χωρίζουμε σε 7-άδες, θέτοντας ως κόμβους-αφετηρία των ομάδων από τον τέταρτο κόμβο έως και τον τέταρτο από το τέλος (αυτό συμβαίνει γιατί οι 3 πρώτοι και οι 3 τελευταίοι δεν συμπληρώνουν ακριβώς την ομάδα τους). Η κάθε ομάδα 7 κόμβων συνδέεται πυκνά με μόνο έναν κόμβο στο επόμενο επίπεδο.

Έτσι για παράδειγμα η πρώτη ομάδα αποτελείται από τους κόμβους **0** έως και **6** , με τον κόμβο **3** να είναι ο κεντρικός, και μεταφέρει πληροφορία μόνο στον κόμβο **0** του επόμενου επιπέδου, καθώς συνδέεται μόνο με αυτόν.

Καθώς σε κάθε επίπεδο θα πρέπει να μειώνεται το q κατά **2n**, έχουμε:

Προτεινόμενη προσέγγιση CLNNs

- First Hidden layer: αποτελείται από **484** κόμβους (εικόνα **22 x 22** , $q=22$ διανύσματα με διάσταση **1x22**)

Επαναλαμβάνουμε την διαδικασία με τις ομάδες και έτσι δημιουργούνται οι κόμβοι του επόμενου επιπέδου. Τώρα το q θα πρέπει να γίνει $q=22 - 6=16$

- Second Hidden layer: αποτελείται από **256** κόμβους (εικόνα **16 x 16** , $q=16$ διανύσματα με διάσταση **1x16**)

Επαναλαμβάνουμε την διαδικασία με τις ομάδες και έτσι δημιουργούνται οι κόμβοι του τελευταίου επιπέδου. Τώρα το q θα πρέπει να γίνει $q=16 - 6=10$

Προτεινόμενη προσέγγιση CLNNs

- Output layer: αποτελείται από **100** κόμβους (εικόνα **10 x 10** , $q=10$ διανύσματα με διάσταση **1x10**)

Επειδή το $q=10 = k$ η διαδικασία σταματάει (ελάχιστος αριθμός κόμβων)

- Final Output layer: Πρόκειται για τους ίδιους κόμβους με το Output layer στους οποίους έχει εφαρμοστεί η συνάρτηση flatten όπου δημιουργεί ένα διάνυσμα **100x1** και όλοι οι κόμβοι είναι πυκνά συνδεδεμένοι . Στην συνέχεια εφαρμόζεται η συνάρτηση ενεργοποίησης SoftMax για την πρόβλεψη της κλάσης.

Προτεινόμενη προσέγγιση CLNNs



Επιβεβαιώνεται λοιπόν ότι τα CLNNs έχουν στοιχεία τόσο από τα Δέντρα Απόφασης καθώς **κάθε κόμβος συνδέεται με ορισμένους** και όχι με όλους (η πληροφορία μεταφέρεται σε μόνο έναν κόμβο) καθώς και από τα Συνελικτικά Νευρωνικά Δίκτυα αφού η **διάσταση των δεδομένων μειώνεται** καθώς η πληροφορία μεταφέρεται από επίπεδο σε επίπεδο , κρατώντας μόνο τα χρήσιμα χαρακτηριστικά στις μικρότερες πλέον εικόνες

03

MCLNNs

Ανάλυση,
Προτεινόμενη Προσέγγιση

Ανάλυση MCLNNs

Όπως ήδη έχουμε αναφέρει τα MCLNNs αποτελούν επέκταση των CLNNs, ακολουθώντας την ίδια λογική.

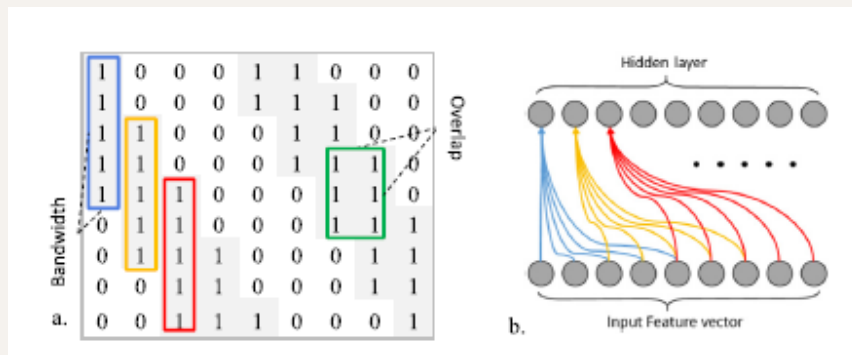


Δυαδική μάσκα (Binary mask) : πίνακας από **0** και **1** ίδιας διάστασης με τα δεδομένα, κατάλληλα κατανεμημένα σύμφωνα με τις τιμές των παραμέτρων **Bandwidth** και **Overlap**. (Οι άσσοι συμβολίζουν ότι θα κρατηθεί η πληροφορία της αντίστοιχης θέσης ενώ τα μηδενικά το αντίθετο)

Ανάλυση MCLNNs

Bandwidth

Το πλήθος των συνεχόμενων
άσων σε κάθε στήλη



Overlap

Οι άσσοι που επικαλύπτονται
σε κάθε στήλη

Σύμφωνα με τα παραπάνω κάθε κόμβος επόμενου επιπέδου συνδέεται μόνο με εκείνους τους κόμβους όπου η Δυαδική μάσκα έχει 1 στις αντίστοιχες θέσεις.

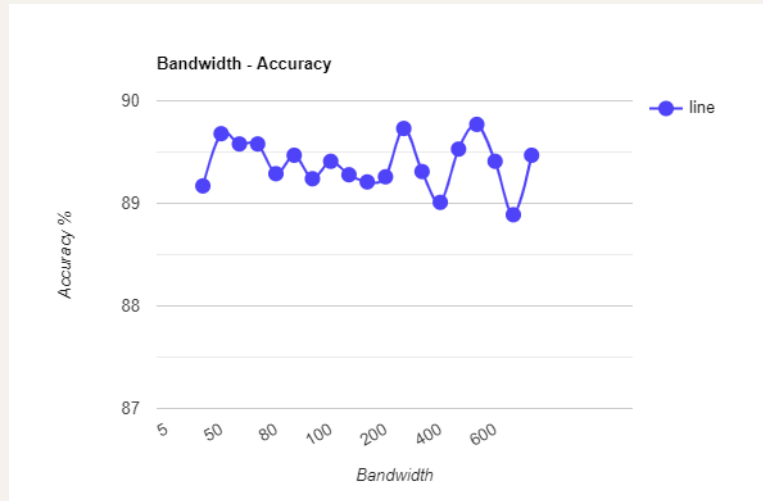
Προτεινόμενη προσέγγιση MCLNNs

Η αρχιτεκτονική και δομή των με μάσκα υπό όρων νευρωνικών δικτύων είναι ίδια, με τις μεταβλητές να έχουν τις ίδιες τιμές:

- $m = 3$ κρυμμένα επίπεδα
- $n = 3$ γείτονες εκατέρωθεν κάθε κόμβου – αφετηρία
- $k = 10$ ελάχιστους κόμβους
- $q = 28$ αρχικά και στη συνέχεια μειώνεται αντίστοιχα σε $22, 16, 10$ σε κάθε επίπεδο
- Τα επίπεδα έχουν ακριβώς τον ίδιο αριθμό κόμβων, αλλά εδώ οι συνδέσεις των νευρώνων μεταξύ των επιπέδων γίνονται με βάση τη δυαδική μάσκα


Προτεινόμενη προσέγγιση MCLNNs

- Μεταβάλλοντας τις τιμές των δύο παραμέτρων Bandwidth και Overlap μεταβάλλεται αντίστοιχα και ο πίνακας της Δυαδικής μάσκας, επηρεάζοντας διαφορετικά την ακρίβεια (**accuracy**) του μοντέλου




Bandwidth - Accuracy Plot

Προτεινόμενη προσέγγιση MCLNNs

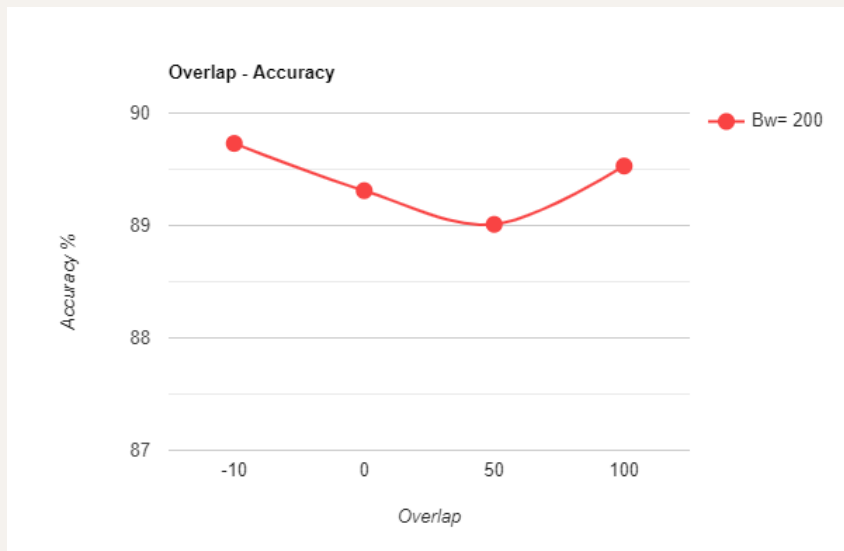


Overlap - Accuracy Plot with Bandwidth=50




Overlap - Accuracy Plot with Bandwidth=100

Προτεινόμενη προσέγγιση MCLNNs



Overlap - Accuracy Plot with Bandwidth=200



Overlap - Accuracy Plot with Bandwidth=400

Προτεινόμενη προσέγγιση Ορθογώνιου πίνακα Δυαδικής μάσκας (Rectangle Mask Matrix schema)

➤ Η προσέγγιση αυτή περιγράφει μια παραλλαγή της Δυαδικής μάσκας όπου :

*οι άσσοι έχουν τοποθετηθεί **μόνο στο κέντρο** του πίνακα, καλύπτοντας το 80% της επιφάνειας του πίνακα και τα μηδενικά έχουν σχηματίσει **ένα περίγραμμα** γύρω από αυτούς. Ως αποτέλεσμα, οι άσσοι έχουν σχηματίσει ένα ορθογώνιο στο κέντρο της μάσκας.*

Αυτό συμβαίνει επειδή έχουμε δώσει προσοχή στη **μορφή του συνόλου δεδομένων** που χρησιμοποιείται. Οι εικόνες στο σύνολο δεδομένων FASHION MNIST **συγκεντρώνουν πληροφορίες κυρίως στο κέντρο** και καθώς οι άσσοι εκδηλώνουν την παρουσία σύνδεσης των κόμβων μεταξύ των επιπέδων οδηγηθήκαμε σε αυτή τη νέα διαφορετική προσέγγιση.

Προτεινόμενη προσέγγιση Ορθογώνιου πίνακα Δυαδικής μάσκας (Rectangle Mask Matrix schema)

- Ένα παράδειγμα αυτής της προσέγγισης (για μικρότερη διάσταση πίνακα)
- Παρατηρούμε ότι οι άσσοι είναι συγκεντρωμένοι στο κέντρο ,εκεί δηλαδή που υπάρχει η χρήσιμη πληροφορία, σχηματίζοντας ένα ορθογώνιο.

[[0 0 0 0 0 0 0 0 0 0]]
[0 0 0 0 0 0 0 0 0 0]
[0 1 1 1 1 1 1 1 1 0]
[0 1 1 1 1 1 1 1 1 0]
[0 1 1 1 1 1 1 1 1 0]
[0 1 1 1 1 1 1 1 1 0]
[0 1 1 1 1 1 1 1 1 0]
[0 1 1 1 1 1 1 1 1 0]
[0 1 1 1 1 1 1 1 1 0]
[0 1 1 1 1 1 1 1 1 0]
[0 1 1 1 1 1 1 1 1 0]
[0 1 1 1 1 1 1 1 1 0]
[0 1 1 1 1 1 1 1 1 0]
[0 1 1 1 1 1 1 1 1 0]
[0 1 1 1 1 1 1 1 1 0]
[0 1 1 1 1 1 1 1 1 0]
[0 1 1 1 1 1 1 1 1 0]
[0 1 1 1 1 1 1 1 1 0]
[0 0 0 0 0 0 0 0 0 0]
[0 0 0 0 0 0 0 0 0 0]]

04

Πειραματικές μετρήσεις

Πειράματα, Τεχνικές Λεπτομέρειες,
Συμπεράσματα

Μετρικές

Υπολογίζουμε ορισμένες σημαντικές μετρήσεις (metrics) για να αξιολογήσουμε και τις τρεις προσεγγίσεις, CLNNs, MCLNNs, και Rectangle Mask Matrix schema :

- ακρίβεια (accuracy)
- συνάρτηση απώλειας (loss function)
- πίνακας σύγχυσης (Confusion matrix)

Πειράματα - CLNNs

➤ Epochs = 25

Metrics for CLNN
with epochs=25

Test accuracy	88.41 %
Test loss	0.324569

Confusion Matrix for
CLNN with
epochs=25

	Class 0	Class 1	Class 2	Class 3	Class 4	Class 5	Class 6	Class 7	Class 8	Class 9
Class 0	81.3 %	0.1 %	1.5 %	2.7 %	0.4 %	0.2 %	13.1 %	0	0.7 %	0
Class 1	0.5 %	96.9 %	0	2 %	0.2 %	0	0.3 %	0	0.1 %	0
Class 2	1.1 %	0.1 %	79.0 %	1.2 %	10.6 %	0.1 %	7.9 %	0	0	0
Class 3	1.5 %	0.6 %	0.9 %	90.1 %	3.0 %	0.2 %	3.4 %	0	0.3 %	0
Class 4	0	0.1 %	7.1 %	2.7 %	84.3 %	0	5.6 %	0	0.2 %	0
Class 5	0	0	0	0.1 %	0	97.2 %	0	1.9 %	0.1 %	0.7 %
Class 6	12.2 %	0.3 %	7.1 %	2.6 %	8.4 %	0	68.5 %	0	0.9 %	0
Class 7	0	0	0	0	0	1.6 %	0	96.1 %	0	2.3 %
Class 8	0.3 %	0.1 %	0.5 %	0.5 %	0.7 %	0.4 %	0.8 %	0.6 %	96.1 %	0
Class 9	0	0	0	0	0	1.2 %	0.1 %	4.0 %	0	94.7 %

Πειράματα - CLNNs

➤ Epochs = 50

Metrics for CLNN
with epochs=50

Test accuracy	88.59 %
Test loss	0.348330

Confusion Matrix for
CLNN with
epochs=50

	Class 0	Class 1	Class 2	Class 3	Class 4	Class 5	Class 6	Class 7	Class 8	Class 9
Class 0	80.0 %	0.4 %	1.5 %	1.7 %	0.2 %	0.1 %	15.2 %	0	0.9 %	0
Class 1	0.4 %	97.0 %	0	1.6 %	0.2 %	0	0.6 %	0	0.2 %	0
Class 2	1.4 %	0.2 %	81.2 %	0.9 %	7.4 %	0.1 %	8.4 %	0	0.4 %	0
Class 3	1.8 %	0.4 %	1.0 %	87.6 %	2.9 %	0	5.9 %	0	0.4 %	0
Class 4	0.1 %	0.1 %	7.7 %	3.1 %	78.1 %	0	10.4 %	0	0.5 %	0
Class 5	0	0	0	0.1 %	0	95.6 %	0.2 %	2.5 %	0.1 %	1.5 %
Class 6	8.2 %	0.2 %	5.9 %	2.6 %	4.8 %	0	77.4 %	0	0.9 %	0
Class 7	0	0	0	0	0	1.1 %	0	96.1 %	0.1 %	2.7 %
Class 8	0.3 %	0.2 %	0	0.5 %	0.3 %	0.2 %	1.2 %	0.4 %	96.9 %	0
Class 9	0	0	0	0	0	0.6 %	0.1 %	3.2 %	0	96.1 %

Πειράματα - CLNNs

➤ Epochs = 100

Metrics for CLNN
with epochs=100

Test accuracy	88.75 %
Test loss	0.490789

Confusion Matrix for
CLNN with
epochs=100

	Class 0	Class 1	Class 2	Class 3	Class 4	Class 5	Class 6	Class 7	Class 8	Class 9
Class 0	83.9 %	0.6 %	1.7 %	2.1 %	0.5 %	0.2 %	10.5 %	0	0.5 %	0
Class 1	0.3 %	97.3 %	0.1 %	1.6 %	0.4 %	0	0.2 %	0	0.1 %	0
Class 2	2.0 %	0.2 %	76.4 %	0.7 %	12.8 %	0.1 %	7.5 %	0	0.3 %	0
Class 3	2.8 %	0.5 %	1.0 %	88.2 %	3.9 %	0	2.9 %	0.1 %	0.6 %	0
Class 4	0.3 %	0	5.3 %	2.2 %	86.9 %	0	4.9 %	0	0.4 %	0
Class 5	0	0	0	0	0	95.8 %	0.1 %	2.4 %	0.3 %	1.4 %
Class 6	12.1 %	0.1 %	5.0 %	1.5 %	9.5 %	0.1 %	70.4 %	0	1.3 %	0
Class 7	0	0	0	0	0	1.4 %	0	95.8 %	0.1 %	2.7 %
Class 8	0.6 %	0	0	0.1 %	0.6 %	0.3 %	0.8 %	0.5 %	97.1 %	0
Class 9	0.1 %	0	0	0	0	1.1 %	0	3.1 %	0	95.7 %

Πειράματα - MCLNNs

➤ Epochs = 25

Metrics for
MCLNN with
epochs=25

Test accuracy	89.46 %
Test loss	0.349775

Confusion Matrix for
MCLNN with
epochs=25

	Class 0	Class 1	Class 2	Class 3	Class 4	Class 5	Class 6	Class 7	Class 8	Class 9
Class 0	87.7 %	0	2.1 %	2.0 %	0.4 %	0.2 %	7.2 %	0	0.4 %	0
Class 1	0.2 %	97.6 %	0.1 %	1.4 %	0.4 %	0	0.1 %	0	0.2 %	0
Class 2	2.4 %	0	86.0 %	1.0 %	6.0 %	0	4.4 %	0	0.2 %	0
Class 3	1.7 %	0.7 %	1.6 %	88.9 %	4.4 %	0	2.1 %	0	0.6 %	0
Class 4	0.2 %	0.1 %	11.8 %	1.2 %	79.4 %	0	7.1 %	0	0.2 %	0
Class 5	0	0	0	0.1 %	0	97.0 %	0	2.1 %	0.1 %	0.7 %
Class 6	13.8 %	0	8.3 %	2.6 %	4.6 %	0	70.0 %	0	0.7 %	0
Class 7	0	0	0	0	0	0.6 %	0	97.3 %	0.1 %	2.0 %
Class 8	0.5 %	0	0.4 %	0.4 %	0.2 %	0.1 %	0.4 %	0.5 %	97.5 %	0
Class 9	0	0	0	0	0	1.1 %	0.1 %	4.1 %	0	94.7 %

Πειράματα - MCLNNs

➤ Epochs = 50

Metrics for
MCLNN with
epochs=50

Test accuracy	89.61 %
Test loss	0.599841

Confusion Matrix for
MCLNN with
epochs=50

	Class 0	Class 1	Class 2	Class 3	Class 4	Class 5	Class 6	Class 7	Class 8	Class 9
Class 0	80.0 %	0.1 %	2.6 %	3.4 %	0.3 %	0.2 %	12.7 %	0	0.6 %	0.1 %
Class 1	0.3 %	96.8 %	0.3 %	1.8 %	0.5 %	0	0.2 %	0	0.1 %	0
Class 2	1.3 %	0	88.2 %	1.8 %	3.9 %	0	4.7 %	0	0.1 %	0
Class 3	1.0 %	0.3 %	1.3 %	91.7 %	3.9 %	0	1.3 %	0	0.5 %	0
Class 4	0.1 %	0	16.1 %	2.6 %	77.9 %	0.1 %	2.9 %	0	0.3 %	0
Class 5	0	0	0.1 %	0	0	93.5 %	0	3.0 %	0.2 %	3.2 %
Class 6	9.5 %	0.1 %	9.7 %	3.6 %	5.9 %	0	70.3 %	0	0.9 %	0
Class 7	0	0	0	0	0	0.7 %	0	96.3 %	0.1 %	2.9 %
Class 8	0.4 %	0	0.8 %	0.8 %	0.1 %	0.3 %	0.2 %	0.4 %	96.9 %	0.1 %
Class 9	0	0	0	0	0	0.2 %	0.1 %	2.0 %	0	97.7 %

Πειράματα - MCLNNs

➤ Epochs = 100

Metrics for
MCLNN with
epochs=100

Test accuracy	89.77 %
Test loss	0.793967

Confusion Matrix for
MCLNN with
epochs=100

	Class 0	Class 1	Class 2	Class 3	Class 4	Class 5	Class 6	Class 7	Class 8	Class 9
Class 0	86.3 %	0.1 %	1.8 %	1.7 %	0.7 %	0.1 %	8.7 %	0.1 %	0.5 %	0
Class 1	0.1 %	98.3 %	0	0.9 %	0.2 %	0	0.3 %	0	0.1 %	0.1 %
Class 2	2.2 %	0.2 %	82.2 %	1.1 %	9.1 %	0	5.2 %	0	0	0
Class 3	1.2 %	0.4 %	0.6 %	90.4 %	4.5 %	0	2.3 %	0	0.6 %	0
Class 4	0.1 %	0	7.3 %	2.1 %	87.4 %	0	2.9 %	0	0.2 %	0
Class 5	0.1 %	0.1 %	0	0.1 %	0	96.6 %	0	1.6 %	0.2 %	1.3 %
Class 6	12.8 %	0.2 %	7.6 %	3.0 %	11.4 %	0	64.4 %	0	0.6 %	0
Class 7	0.1 %	0	0	0	0	1.5 %	0	97.4 %	0	1.0 %
Class 8	0.6 %	0	0.2 %	0.4 %	0.5 %	0.1 %	0.4 %	0.2 %	97.6 %	0
Class 9	0.1 %	0	0	0	0	1.2 %	0.1 %	4.6 %	0	94.0 %

Πειράματα – MCLNNs - Rectangle Mask Matrix

➤ Epochs = 25

Metrics for MCLNN -
Rectangle Mask
Matrix with
epochs=25

Test accuracy	89.09%
Test loss	0.380718

Confusion Matrix for
MCLNN - Rectangle
Mask Matrix with
epochs=25

	Class 0	Class 1	Class 2	Class 3	Class 4	Class 5	Class 6	Class 7	Class 8	Class 9
Class 0	86.5 %	0.4 %	2.2 %	2.1 %	0.5 %	0.1 %	7.2 %	0	1.0 %	0
Class 1	0	98.8 %	0	0.6 %	0.3 %	0	0.2 %	0	0.1 %	0
Class 2	1.7 %	0.1 %	86.3 %	1.3 %	7.7 %	0	2.9 %	0	0	0
Class 3	2.0 %	1.2 %	1.1 %	90.9 %	3.4 %	0	1.1 %	0	0.3 %	0
Class 4	0.1 %	0.1 %	9.7 %	2.8 %	85.3 %	0	1.8 %	0	0.2 %	0
Class 5	0	0	0	0.1 %	0	96.9 %	0	2.2 %	0	0.8 %
Class 6	13.7 %	0.2 %	11.9 %	3.3 %	12.0 %	0	57.8 %	0	1.1 %	0
Class 7	0	0	0	0	0	1.1 %	0	97.6 %	0	1.3 %
Class 8	0.4 %	0.1 %	0.2 %	0.5 %	0.5 %	0.3 %	0.8 %	0.4 %	96.8 %	0
Class 9	0	0	0	0	0	1.2 %	0.1 %	4.7 %	0	94.0 %

Πειράματα – MCLNNs - Rectangle Mask Matrix

➤ Epochs = 50

Metrics for MCLNN -
Rectangle Mask
Matrix with
epochs=50

Test accuracy	89.31%
Test loss	0.531949

Confusion Matrix for
MCLNN - Rectangle
Mask Matrix with
epochs=50

	Class 0	Class 1	Class 2	Class 3	Class 4	Class 5	Class 6	Class 7	Class 8	Class 9
Class 0	86.8 %	0.1 %	1.9 %	1.5 %	0.6 %	0.2 %	7.5 %	0	1.4 %	0
Class 1	0.4 %	97.9 %	0.1 %	1.0 %	0.4 %	0	0.1 %	0	0.1 %	0
Class 2	2.1 %	0.1 %	78.7 %	1.3 %	13.1 %	0	3.9 %	0	0.8 %	0
Class 3	1.7 %	0.4 %	1.3 %	91.3 %	3.4 %	0	1.5 %	0	0.4 %	0
Class 4	0	0.1 %	3.7 %	2.9 %	89.4 %	0	3.2 %	0	0.7 %	0
Class 5	0	0	0.1 %	0.1 %	0	95.8 %	0	2.7 %	0.1 %	1.2 %
Class 6	14.2 %	0.2 %	7.4 %	2.9 %	10.9 %	0	62.6 %	0	1.8 %	0
Class 7	0	0	0	0	0	0.5 %	0	98.3 %	0	1.2 %
Class 8	0.4 %	0	0.4 %	0.2 %	0.3 %	0.1 %	0.1 %	0.4 %	98.1 %	0
Class 9	0	0	0	0	0	0.8 %	0.1 %	4.9 %	0	94.2 %

Πειράματα – MCLNNs - Rectangle Mask Matrix

➤ Epochs = 100

Metrics for MCLNN -
Rectangle Mask
Matrix with
epochs=100

Test accuracy	89.37 %
Test loss	0.763854

Confusion Matrix for
MCLNN - Rectangle
Mask Matrix with
epochs=100

	Class 0	Class 1	Class 2	Class 3	Class 4	Class 5	Class 6	Class 7	Class 8	Class 9
Class 0	87.0 %	0.1 %	2.0 %	0.9 %	0.3 %	0.2 %	9.3 %	0	0.2 %	0
Class 1	0.5 %	98.3 %	0	0.5 %	0.4 %	0	0.3 %	0	0	0
Class 2	2.1 %	0.1 %	87.1 %	0.5 %	4.0 %	0.1 %	6.0 %	0	0.1 %	0
Class 3	3.8 %	1.1 %	1.9 %	85.1 %	4.1 %	0	3.6 %	0	0.4 %	0
Class 4	0.3 %	0.3 %	127%	1.8 %	79.3 %	0	5.4 %	0	0.2 %	0
Class 5	0	0	0	0	0	96.9 %	0	1.8 %	0.3 %	1.0 %
Class 6	14.9 %	0.1 %	9.5 %	1.9 %	6.1 %	0	67.0 %	0.1 %	0.4 %	0
Class 7	0	0	0	0	0	0.6 %	0	97.2 %	0	2.2 %
Class 8	0.9 %	0	0.6 %	0.4 %	0.1 %	0.1 %	0.2 %	0.4 %	97.3 %	0
Class 9	0.1 %	0	0	0	0	0.8 %	0.1 %	2.7 %	0.1 %	96.2 %

Συμπεράσματα

- Καθώς ο αριθμός των εποχών αυξάνεται, μπορούμε να παρατηρήσουμε ότι αυξάνεται και η ακρίβεια. Αυτό σημαίνει ότι το μοντέλο μας τρέχει το σύνολο δεδομένων εκπαίδευσης όλο και περισσότερες φορές, παράγοντας καλύτερες και πιο ακριβείς προβλέψεις.
- Καθώς ο αριθμός των εποχών αυξάνεται, μπορούμε να παρατηρήσουμε ότι αυξάνεται και η συνάρτηση απώλειας. Αυτό συμβαίνει λόγω του φαινομένου της **υπερεκπαίδευσης (overfitting)**. [Δεν αυξάνεται ο αριθμός των λανθασμένων προβλέψεων, απλά το μοντέλο “επιμένει” στις ίδιες εσφαλμένες προβλέψεις].
- **Γενικά**, στα σύνολα δεδομένων MNIST, παρατηρείται συχνά η υπερεκπαίδευση. (μοναδιαία pixels, “περίεργα” pixels)

89.77 %

Είναι η υψηλότερη τιμή ακρίβειας (**accuracy**) όλων των πειραμάτων και εντοπίζεται στα Masked Conditional Neural Networks στην περίπτωση των epochs=100.

➤ Η ακρίβεια όλων των πειραμάτων και μοντέλων συνολικά κυμαίνεται στο 88-90 %

Επεκτάσεις

Παράμετροι του
μοντέλου

n, m, k

Δυναδική μάσκα

Bandwidth, Overlap,
άλλες παραλλαγές

Σύνολο Δεδομένων

Image classification σε
άλλο σύνολο
δεδομένων(πχ. Ιατρική)

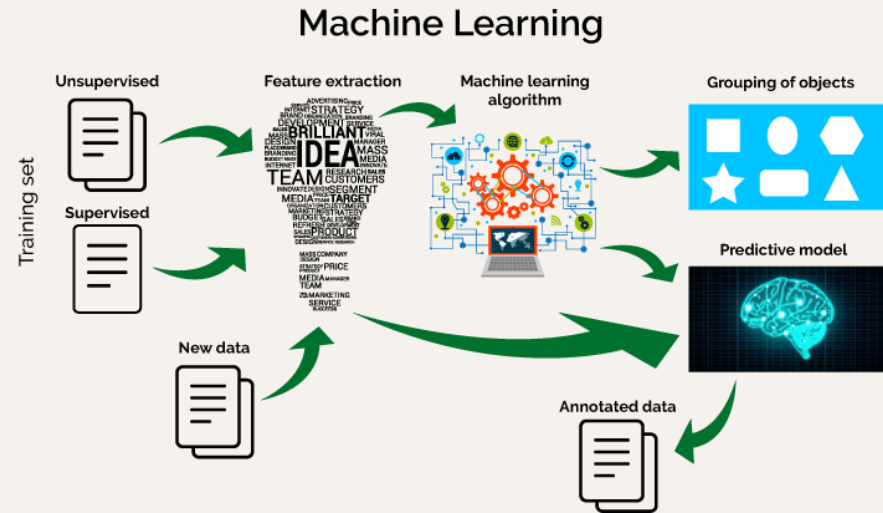
Είδος Δεδομένων

Εκτός από εικόνες,
επέκταση σε
πολυδιάστατα δεδομένα,
σήματα κτλ.



Επίλογος

- Η Μηχανική Μάθηση αποτελεί ένα σημαντικό μέρος του ταχέως αναπτυσσόμενου κλάδου της επιστήμης δεδομένων με τους αλγορίθμους να εκπαιδεύονται κατάλληλα ώστε να δημιουργούν ταξινομήσεις ή προβλέψεις σε προβλήματα εξόρυξης, επεξεργασίας και κατηγοριοποίησης δεδομένων σε όλους τους τομείς.



Τεχνικές Λεπτομέρειες

- Python 3.9.2 και Editor: Visual Studio Code
- Βιβλιοθήκες : TensorFlow.keras (Input, Lambda, Dense, Concatenate) , pandas, sklearn, NumPy, matplotlib, math, datetime
- Κανονικοποίηση δεδομένων σε τιμές από 0 έως 1
- Functional API : περισσότερο ευέλικτο και δυναμικό σε επεκτάσεις
- Loss function: sparse_categorical_crossentropy (οι ετικέτες είναι ακέραιοι)
- Adam Optimizer με learning rate=0.0001

Χρήσιμη Βιβλιογραφία

- F. Medhat, D. Chesmore, and J. Robinson, **Masked Conditional Neural Networks for Environmental Sound Classification**, Cornell University, USA, 27 April 2019
- G. Singh Sohi, **Conditional Neural Networks**, GOOD AUDIENCE, 5 July 2018
- S. Saha, **A Comprehensive Guide to Convolutional Neural Networks**, Towards data science, 15 December 2018
- J. Brownlee, **Deep Learning CNN for Fashion-MNIST Clothing Classification**, Deep Learning for Computer Vision, 10 May 2019
- P. Vadapalli, **Decision Tree in AI: Introduction, Types & Creation**, upGrad, 3 September 2020

Σας ευχαριστώ για το χρόνο
και την προσοχή σας!